
# Agenda

Часть 1. Создание кластера Arenadata Hadoop. Работа с HDFS	2
Создание кластера Arenadata Hadoop Community Test	2
Подключение к кластеру через ssh	4
Создание домашнего каталога в HDFS	5
Загрузка данных в домашний каталог HDFS	5
Вывод содержимого файлов в HDFS	6
Распределение блоков по узлам кластера	6
Расположение блоков на узлах в локальной ОС	7
Часть 2. Запуск задач Мар Reduce	8
Запустите MR-задачу WordCount для загруженных данных	8
Выведите результат работы алгоритма	9
Отобразите информацию по выполненной задаче через консоль YARN.	9
Часть 3. Сжатие файлов в Hadoop. Запуск MR-задач для сжатых данных.	10
Произведите сжатие загруженных данных кодаками: GzipCodec и BZip2Codec	10
Запустите MR-задачу WordCount для каждого из сжатых файлов	11


### Часть 1. Создание кластера Arenadata Hadoop. Работа с HDFS

#### Создание кластера Arenadata Hadoop Community Test


1. Перейдите в личный кабинет VK Cloud. Откройте раздел «Большие Данные» и выберите «Создание кластеров Arenadata Hadoop Community и Enterprise».




2. Выберите конфигурацию «ADH Community Test v. 2.1.4\_b10»




3. Настройте сеть для вашего кластера и добавьте следующие компоненты: **ADCM, HDFS, MAPREDUCE, YARN, ZOOKEEPER** 




4. Укажите конфигурацию узлов Master1, Master2, Workers и Edge (установите соответствующий переключатель):




Назначьте внешний IP для инстанса ADCM



5. Компоненты оставьте без изменений




6. Укажите пароль для ADCM (Arenadata Cluster Manager). Создайте SSH-ключ в формате RSA для подключения к узлу. Запустите создание кластера (длительность операции 20-30 минут).




#### Подключение к кластеру через ssh

- 1. Установите или используйте стандартный ssh-клиент. Для настройки подключения воспользуйтесь инструкцией <u>Подключение к Linux BM</u>.
- 2. Используйте внешний IP адрес для ssh-клиента (пользователь admin):




3. Дождитесь установки кластера.

Для проверки статуса установки кластера перейдите по ссылке «http://<Внешний IP адрес>:8000» (например, <a href="http://85.192.34.31:8000">http://85.192.34.31:8000</a>). Введите учетные данные для ADCM:



Проверьте статус выполнения задачи Install/ADH.



4. Запустите команду для проверки работоспособности кластера: hadoop fs -1s /

```
### admin@ADH-cluster8176c6049016-Edge-0 ~|S hadoop fs -ls /
Found 4:Less 176c6049016-Edge-0 ~|S hadoop fs -ls /
Found 4:Less -yarn hadoop 0 2023-03-25 08:22 /logs
drwxr.wxrwt - yarn hadoop 0 2023-03-25 08:22 /logs
drwxr.wxrwx - hdfs hadoop 0 2023-03-25 08:20 /system
drwxr.wxrwx - hdfs hadoop 0 2023-03-25 08:25 /tmp
drwxr.wxrwx - hdfs hadoop 0 2023-03-25 08:25 /tmp
drwxr.wxrwx - hdfs hadoop 0 2023-03-25 08:20 /user
[admin@ADH-cluster8176c6049016-Edge-0 ~]$ |
```

#### Создание домашнего каталога в HDFS

1. Создайте домашнюю директорию для текущего пользователя Linux в HDFS

#### Пояснение для преподавателя:

sudo -u hdfs hadoop fs -mkdir /user/admin

2. Смените владельца и группу созданного каталога на admin

#### Пояснение для преподавателя:

sudo -u hdfs hadoop fs -chown admin:admin /user/admin

3. Проверьте владельца каталога в HDFS

#### Пояснение для преподавателя:

```
      hadon pADH-buted176:00:0016-Edge-0

      [adminBADH-cluster8176:00:0016-Edge-0
      ~15 hadoop fs -1s /user

      Evoud 5 items
      admin admin
      0 2023-03-25 09:18 /user/admin

      drwxr-xr-x
      - admin admin
      0 2023-03-25 08:17 /user/hdfs

      drwxr-xr-x
      - mapred hadoop
      0 2023-03-25 08:17 /user/hdfs

      drwxr-xr-x
      - mapred hadoop
      0 2023-03-25 08:12 /user/history

      drwxr-xr-x
      - mapred napred
      0 2023-03-25 08:20 /user/mapred

      drwxr-xr-x
      - yann yarn
      0 2023-03-25 08:26 /user/yarn

      [admin8DaH-cluster8176:e60d9016-Edge-0] ~ | $\frac{1}{2}$
      | user/yarn
```

#### Загрузка данных в домашний каталог HDFS

1. Загрузите файлы nseCompBig.zip и nseCompSmall.zip на узел кластера (например, используя curl или wget). Скачать (временно) файлы можно по ссылкам, соответственно:

https://disk.yandex.ru/d/PoXJ2YsKh2HZlw https://disk.yandex.ru/d/QbLvf4KUFubO7A

2. Разархивируйте загруженные файлы на узле в домашнюю директорию

#### Пояснение для преподавателя:

```
unzip /tmp/nseCompSmall.zip
unzip /tmp/nseCompBig.zip
```

3. Создайте директорию staging/input/stocks/ в HDFS

#### Пояснение для преподавателя:

```
hadoop fs -mkdir -p staging/input/stocks/
```

4. Загрузите файлы nseCompBig.csv и nseCompSmall.csv в HDFS каталог staging/input/stocks/

#### Пояснение для преподавателя:

```
hadoop fs -put nseCompSmall.csv staging/input/stocks/nseCompSmall.csv hadoop fs -put nseCompBig.csv staging/input/stocks/nseCompBig.csv
```

#### Вывод содержимого файлов в HDFS

Выведите несколько строк файлов nseCompBig.csv и nseCompSmall.csv в HDFS (hadoop fs [-tail|cat|head])

#### Пояснение для преподавателя:

hadoop fs -tail staging/input/stocks/nseCompSmall.csv

```
### Amme ADH charts The Administration of the Company of the Compa
```

hadoop fs -tail staging/input/stocks/nseCompBig.csv

```
## Action ## Ac
```

#### Распределение блоков по узлам кластера

Выведите распределение блоков по узлам кластера для фалов nseCompBig.csv и nseCompSmall.csv в HDFS (hdfs fsck)

#### Пояснение для преподавателя:

```
hdfs fsck staging/input/stocks/nseCompSmall.csv -files -blocks
-locations
```

#### hdfs fsck staging/input/stocks/nseCompBig.csv -files -blocks -locations

```
| Cambridge | Company | Co
```

#### Расположение блоков на узлах в локальной ОС

1. Найдите имя блока файла в выводе команды hdfs fsck

```
/user/admin/staging/input/stocks/nsecompsmall.csv 366356750 bytes, replicated: replication=3, 3 block(s): OK

0.8P-1262089974-10.0.0.7-167973765470-ibk_1073741883_1046 lene=13421728_ibve_repl=3 [DatamodeInfoWithStorage[10.0.0.18:9866,D8-948395c-7da9-414c-b669-b755be3fa943,DISK], DatamodeInfoWithStorage[10.0.0.2:9866,D8-36389040-21d4-49c2-8d67-f0f0fa7058d1,DISK]]


1.8P-1262089974-10.0.7-167973756470-ibk_1073741889_1065 lene=13421778_ibve_repl=3 [DatamodeInfoWithStorage[10.0.0.2:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK]]

1.8P-1262089974-10.0.7-167973756470-ibk_1073741889_1065 lene=13421778_ibve_repl=3 [DatamodeInfoWithStorage[10.0.0.2:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK]]


1.8P-1262089974-10.0.0.18:9866,D8-946895c-7da9-414c-b669-b755be3fa943,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK]]

1.8P-1262089974-10.0.0.7-16797575265470-ibk_1073741890_1066 lene=19721294_Live_repl=3 [DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-3684950c-7da9-414c-b669-b755be3fa943,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK], DatamodeInfoWithStorage[10.0.0.32:9866,D8-36389040-21d4-9c2-8d67-f0f0fa7058d1,DISK]
```

Подключитесь через SSH к любой hdfs-datanode.
 Выберите любой узел Workers во вкладке ADCM -> HOSTS (например, ADH-CLUSTER83258CA307E7-WORKERS-0.MCS.LOCAL)



Откройте настройки узла (Configuration) и скопируйте поле «SSH private key» для доступа по ssh c Edge-узла.



3. Выполните поиск в локальной ОС в директории /srv/hadoop-hdfs -name (find)

#### Пояснение для преподавателя:

sudo find /srv/hadoop-hdfs -name \*blk\_1073741888\*

```
# admin@ADH-duste@25kca307e7-Workers-0 ~ ]$ sudo find /srv/hadoop-hdfs -name *blk 1073741888*
/srv/hadoop-hdfs/data/current/BB-1262089974-10.0.0.7-1679757265470/current/finalized/subdir0/subdir0/blk 1073741888 1064.meta
/srv/hadoop-hdfs/data/current/BB-1262089974-10.0.0.7-1679757265470/current/finalized/subdir0/subdir0/blk 1073741888 1064.meta
/srv/hadoop-hdfs/data/current/BB-1262089974-10.0.0.7-1679757265470/current/finalized/subdir0/subdir0/blk 1073741888 1064.meta
```

4. Выведите содержимое блока в локальной ОС (cat, head, tail)

#### Пояснение для преподавателя:

sudo head

/srv/hadoop-hdfs/data/current/BP-1262089974-10.0.0.7-1679757265470/current/finalized/subdir0/subdir0/blk\_1073741888

```
# admin@ADH-duteN25836107-Weden-0-
[admin@ADH-duteN25836107-Weden-0-]$ sudo head /srv/hadoop-hdfs/data/current/BP-1262089974-10.0.0.7-1679757265470/current/finalized/subdir0/subdir0/blk_1073741888
1.3 IINFOTECH_20150703, 09:16:00, 4.55, 4.55, 4.55, 4.55, 4.55, 835
2.3 IINFOTECH_20150703, 09:18:00, 4.55, 4.55, 4.55, 4.55, 390
3.3 IINFOTECH_20150703, 09:18:00, 4.55, 4.55, 4.55, 4.55, 4.55, 100
4.3 IINFOTECH_20150703, 09:18:00, 4.55, 4.55, 4.55, 4.55, 110
5.3 IINFOTECH_20150703, 09:20:00, 4.55, 4.55, 4.55, 4.55, 4.50, 100
5.3 IINFOTECH_20150703, 09:20:00, 4.55, 4.55, 4.55, 4.55, 4.50, 100
7.3 IINFOTECH_20150703, 09:22:00, 4.55, 4.55, 4.55, 4.55, 4.50, 100
8.3 IINFOTECH_20150703, 09:22:00, 4.55, 4.55, 4.55, 4.55, 4.50, 100
9.3 IINFOTECH_20150703, 09:22:00, 4.55, 4.55, 4.55, 4.55, 5.50
9.3 IINFOTECH_20150703, 09:22:00, 4.55, 4.55, 4.55, 4.55, 4.55, 5.50
9.3 IINFOTECH_20150703, 09:22:00, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55, 4.55,
```

## Часть 2. Запуск задач Мар Reduce

#### Запустите MR-задачу WordCount для загруженных данных

1. Ознакомьтесь с возможностями стандартных примеров запуска MR-задач Hadoop (hadoop-mapreduce-examples-3.1.2.jar)

#### Пояснение для преподавателя:

hadoop jar
/usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples-3.1.2.jar

```
Activation of the design of the second program of the second progr
```

2. Запустите MR-задачу wordcount для файла nseCompSmall.csv. Coxpаните результат работы алгоритма в HDFS каталог output/mapreduce/wordcount/nseCompSmall

#### Пояснение для преподавателя:

```
hadoop jar
/usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples-3.1.2.jar wordcount
staging/input/stocks/nseCompSmall.csv
output/mapreduce/wordcount/nseCompSmall
```

```
### Annual Content of the Content of
```

#### Выведите результат работы алгоритма

Выведите содержимое файла результата вычислений (используйте команду hadoop fs -head, т.к. вывод команды hadoop fs -cat может быть объемным)

#### Пояснение для преподавателя:

hadoop fs -head output/mapreduce/wordcount/nseCompSmall/part-r-00000

```
### Amenda | Amenda |
```

#### Отобразите информацию по выполненной задаче через консоль YARN.

1. Найдите имя MR-задачи с помощью вывода списка выполненных (FINISHED) задач (yarn application -list).

#### Пояснение для преподавателя:

yarn application -appStates FINISHED -list



2. Изучите вывод лога MR-задачи (yarn logs -applicationId)

#### Пояснение для преподавателя:

yarn logs -applicationId application\_1679757608310\_0003

# Часть 3. Сжатие файлов в Hadoop. Запуск MR-задач для сжатых данных.

Произведите сжатие загруженных данных кодаками: GzipCodec и BZip2Codec Сжатие исходных данных можно выполнить с помощь MR-задачи:

• Для кодака Gzip:

hadoop jar /usr/lib/hadoop-mapreduce/hadoop-streaming-\*.jar -D mapreduce.job.reduces=1 -D mapred.output.compress=true -D mapred.output.compression.codec=org.apache.hadoop.io.compress.GzipCodec -D mapreduce.output.fileoutputformat.compress.type=RECORD -mapper /bin/cat -reducer /bin/cat -input staging/input/stocks/nseCompBig.csv -output staging/input/stocks/gzip\_big

• Для кодака Вzір2:

hadoop jar /usr/lib/hadoop-mapreduce/hadoop-streaming-\*.jar -D mapreduce.job.reduces=1 -D mapred.output.compress=true -D

mapred.output.compression.codec=org.apache.hadoop.io.compress.BZip2Codec -D mapreduce.output.fileoutputformat.compress.type=RECORD -mapper /bin/cat -reducer /bin/cat -input staging/input/stocks/nseCompBig.csv -output staging/input/stocks/bzip2\_big

Результатами выполнения указанных задач будут сжатые файлы:

```
-rw-r--r- 3 admin admin 267980233 staging/input/stocks/bzip2_big/part-00000.bz2
-rw-r--r- 3 admin admin 368726919 staging/input/stocks/gzip_big/part-00000.gz
```

#### Запустите MR-задачу WordCount для каждого из сжатых файлов

1. Запустите MR-задачу WordCount для файла staging/input/stocks/gzip\_big/part-00000.gz и каталогом вывода результатов output/mapreduce/wordcount/nseCompGzip.

#### Пояснение для преподавателя:

hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples-3.1.2.jar wordcount staging/input/stocks/gzip\_big/part-00000.gz output/mapreduce/wordcount/nseCompGzip

 Запустите MR-задачу WordCount для файла staging/input/stocks/bzip2\_big/part-00000.bz2 и каталогом вывода результатов output/mapreduce/wordcount/nseCompBzip2.

#### Пояснение для преподавателя:

hadoop jar /usr/lib/hadoop-mapreduce/hadoop-mapreduce-examples-3.1.2.jar wordcount staging/input/stocks/bzip2\_big/part-00000.bz2 output/mapreduce/wordcount/nseCompBzip2

```
### description of the content of th
```

- 3. Объясните количество выделенных Mapper's MR-задачи для файлов:
- part-00000.gz Launched map tasks=1,
- part-00000.bz2 Launched map tasks=2?

#### Пояснение для преподавателя:

При вычислении MR-задачи для сжатых файлов Hadoop выполняет декомпрессию локально на узлах, где будут запускаться Mapper's. Количество блоков в HDFS для сжатых данных не будет влиять на количество выделяемых Mapper's для MR-задачи.

Количество выделенных Mapper's объясняется способом сжатия. Кодак Bzip2 создает сплитируемый сжатый файл, что даёт возможность запустить для каждого сплита свой Mapper.

Кодак Gzip создает сжатый файл без сплитов, т.е. Маррег будет один!